

Skład grupy:

Małgorzata Dąbrowska – 281404

Maciej Kanar – 281350

Jakub Buszkiewicz – 281373

Temat projektu: Przewidywanie jakości wina na podstawie składu chemicznego

Link do GitHuba:

https://github.com/EchoNewTech/wine_quality_msi.git

PLAN EKSPERYMENTÓW:

1. Testowanie algorytmów klasyfikacyjnych i wstępna selekcja

CEL Znalezienie optymalnego modelu klasyfikacyjnego do predykcji jakości wina na podstawie jego parametrów chemicznych.

PRZEBIEG W eksperymencie zostaną przetestowane wybrane modele klasyfikacyjne: Random Forest, SVM, kNN, drzewo decyzyjne oraz GNB. Skuteczność modeli zostanie oszacowana za pomocą 5-krotnej walidacji krzyżowej. Do ostatecznego porównania zostanie obliczone: accuracy, średnia wartości F1-score (macro) wraz z odchyleniem standardowym. Dodatkowo, w celu potwierdzenia istotności statystycznej różnic między wynikami najlepszych modeli, przeprowadzony zostanie test T-Studenta.

2. Znaczenie cech i porównanie

CEL Identyfikacja kluczowych parametrów decydujących o jakości wina (z wyłączeniem informacji o jego kolorze) oraz analiza zachowania modeli.

PRZEBIEG Wybrane w poprzednim kroku algorytmy zostaną poddane analizie istotności cech, aby wskazać, które komponenty chemiczne mają największy wpływ na predykcję. W tym celu wykorzystana zostanie metoda wartości SHAP (Shapley Additive exPlanations), co pozwoli na precyzyjne określenie kierunku i siły wpływu każdego komponentu chemicznego na ostateczną predykcję modelu. Następnie przeprowadzone zostanie porównanie metryk skuteczności użytych metod oraz analiza macierzy pomyłek. Pozwoli to zidentyfikować, pomiędzy którymi konkretnie klasami (np. czy wina o jakości 5 są najczęściej mylone z jakością 6, czy 4) modele popełniają błędy.

3. Uproszczenie problemu do klasyfikacji binarnej (Premium vs Non-Premium)

CEL Ocena, jak uproszczenie przestrzeni decyzyjnej poprzez zmniejszenie liczby klas wpływa na stabilność i skuteczność predykcji modeli, ze szczególnym uwzględnieniem zdolności do poprawnego wykrywania win wysokiej jakości.

PRZEBIEG Przekształcenie klasyfikacji wieloklasowej w binarną, gdzie wina oceniane na 7 lub więcej uznawane są za klasę „Premium” (1), zaś pozostałe zostaną uznane za klasę „Standard” (0). Następnie zbadana zostanie skuteczność wybranego w Eksperymencie 1 modelu na tak przekształconym zbiorze danych.

4. Analiza wpływu rodzaju wina na predykcję i ważność cech

CEL Zbadanie różnic w strukturze cech w zależności od koloru wina.

PRZEBIEG Test sprawdzający zdolność modelu do klasyfikacji po kolorze wina na podstawie cech chemicznych. Następnie całkowity zbiór zostanie rozdzielony na dwa podzbiory: wino białe i czerwone. Na obu podzbiorach zostaną wytrenowane próbki na

modelu wskazanym w eksperymencie pierwszym osobno dla obu tych grup. Eksperyment pozwoli na bezpośrednie porównanie rankingów ważności cech i zweryfikuje, czy te same parametry chemiczne decydują o jakości wina białego i czerwonego.

5. Przewidzenie teoretycznie idealnych parametrów wina dla wina białego i czerwonego

CEL Wyznaczenie profilu idealnego wina na podstawie win najwyższej klasy.

PRZEBIEG Eksperyment zostanie przeprowadzony na oryginalnych (nieznormalizowanych) danych wejściowych. Wybrane zostanie 5% najwyżżej ocenionych próbek. Poprzez obliczenie średnich arytmetycznych oraz median dla każdego z parametrów w tej grupie, wyznaczone zostaną dwie teoretyczne, optymalne kompozycje wina (osobno dla wina białego i czerwonego). Ten nowy przepis "podajemy" naszemu najlepszemu modelowi (z Eksperymentu 1) i sprawdzamy, jaką ocenę mu wystawi. Eksperyment ma dowieść, czy algorytm wyszkolony na prawdziwych winach rozpozna w tej uśrednionej kompozycji produkt najwyższej jakości.